

Aufgabe 1: Lineare Einfachregression

Der auf der Moodle-Homepage verfügbare Datensatz `RunningAgg.Rds` enthält Informationen zu einstündigen Laufeinheiten von 345 Hobbyläufern. Für die einzelnen Läufer sind die durchschnittliche Pace (`pace`, Kehrwert der Geschwindigkeit) in *min/km* sowie die zugehörige durchschnittliche Herzfrequenz (`HR`) in *bpm* (beats per minute) gegeben.

- (a) Lesen Sie den Datensatz in **R** ein und visualisieren Sie den Zusammenhang zwischen der Laufgeschwindigkeit (`pace`) und der Herzfrequenz (`HR`). Passen Sie ein Lineares Modell für diesen Zusammenhang an und interpretieren Sie die Parameterschätzer $\hat{\beta}_0$ und $\hat{\beta}_1$.
- (b) Warum könnte es sinnvoller sein, den Zusammenhang zwischen der Geschwindigkeit (in *km/h*) und der Herzfrequenz zu untersuchen? Passen Sie das Modell mit der neuen Einflussgröße erneut an. Vergleichen Sie die Anpassung der beiden Modelle.
- (c) Leiten Sie die Umrechnungsformel für die Kleinst-Quadrate-Schätzer nach einer linearen Variablentransformation der folgenden Form her:

$$\begin{aligned}x_i &\rightarrow t_i = a_0 + a_1 x_i, & \text{mit } a_1 \neq 0 \\y_i &\rightarrow u_i = b_0 + b_1 y_i, & \text{mit } b_1 \neq 0\end{aligned}$$

- (d) Wie ändern sich die Parameterschätzungen, wenn die Geschwindigkeit in Meilen pro Stunde ($1 \text{ mi} = 1.61 \text{ km}$) und die Herzfrequenz in Schläge pro Sekunde (*bps*) umgerechnet werden? Berechnen Sie hierzu die neuen Schätzungen anhand der Ergebnisse aus Teilaufgabe (b). Hätten hierfür auch die Ergebnisse aus Teilaufgabe (a) verwendet werden können?
- (e) Betrachten Sie nun erneut das Modell aus Teilaufgabe (b). Zentrieren Sie die Einflussvariable `speed` und passen Sie das Modell mit der zentrierten Variable neu an. Interpretieren Sie die geschätzten Parameter.
- (f) Berechnen Sie die Parameterschätzer nun direkt aus den Parameterschätzern des Modells aus Teilaufgabe (c). Vergleichen Sie dazu die geschätzten Parameter aus Teilaufgabe (a).
- (g) Betrachten Sie nun das Regressionsmodell $\tilde{HR}_i = \gamma_0 + \gamma_1 \tilde{speed}_i + \varepsilon_i$, wobei \tilde{HR} und \tilde{speed} jeweils die standardisierten Versionen der entsprechenden Variablen darstellen. Vergleichen Sie den Koeffizientenschätzer $\hat{\gamma}_1$ mit dem Bravais-Pearson-Korrelationskoeffizienten zwischen den beiden Variablen. Was fällt dabei auf?

Aufgabe 2: Eigenschaften der Koeffizientenschätzer

- (a) Betrachten Sie das einfache lineare Regressionsmodell (siehe Vorlesung, Folie 19)

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i; \quad i = 1, \dots, n$$

mit den Annahmen

$$\begin{aligned} E(\epsilon_i) &= 0; \quad i = 1, \dots, n \\ \text{Var}(\epsilon_i) &= \sigma^2; \quad i = 1, \dots, n \\ \{\epsilon_i \mid i = 1, \dots, n\} &\quad \text{stochastisch unabhängig} \\ \epsilon_i &\sim N(0, \sigma^2); \quad i = 1, \dots, n. \end{aligned}$$

Leiten Sie die Varianzen $\text{Var}(\hat{\beta}_0)$ und $\text{Var}(\hat{\beta}_1)$ der Koeffizientenschätzer $\hat{\beta}_0$ und $\hat{\beta}_1$ her (Gleichungen (1.13) und (1.14) aus der Vorlesung Folie 26).

- (b) Veranschaulichen Sie anhand einer Simulation in **R**, dass die Koeffizientenschätzer des in Teilaufgabe (b) beschriebenen einfachen linearen Regressionsmodells folgende Verteilungen besitzen:

$$\begin{aligned} \hat{\beta}_0 &\sim N(\beta_0, \text{Var}(\hat{\beta}_0)) \\ \hat{\beta}_1 &\sim N(\beta_1, \text{Var}(\hat{\beta}_1)). \end{aligned}$$

Verwenden Sie hierzu den folgenden Regressionszusammenhang zur Durchführung von $N = 10.000$ Simulationen:

$$Y_i = -2 + 3.5 \cdot x_i + \epsilon_i \quad \text{mit } \epsilon_i \sim N(0, 10).$$

Aufgabe 3: Quadratsummenzerlegung

In einer Erfassung verschiedener Merkmale von Baseball-Spielern der Major League Baseball (MLB) wurden unter anderem die Körpergröße (in cm) sowie das Gewicht (in kg) der Spieler erhoben. Für 10 zufällig ausgewählte Spieler liegen folgende Werte vor:

Spieler i	1	2	3	4	5	6	7	8	9	10
Größe x_i	198	188	196	190	180	183	196	196	193	183
Gewicht y_i	104	84	107	95	76	79	109	94	113	93

Hinweis: Für die Teilaufgaben (b)-(d) kann **R** als Taschenrechner verwendet werden.

- (a) Zeichnen Sie die Information in ein Streudiagramm. Welcher Zusammenhang ist zwischen Körpergröße und Gewicht erkennbar?
- (b) Berechnen Sie die Gesamtstreuung (SST) der Variable **Gewicht**.
- (c) Bestimmen Sie per Hand die Koeffizientenschätzer $\hat{\beta}_0$ und $\hat{\beta}_1$ für ein lineares Regressionsmodell, das das Gewicht in Abhängigkeit der Körpergröße modelliert.
- (d) Berechnen Sie mit Hilfe der in Teilaufgabe (c) bestimmten Parameter die Streuung, die durch das Modell erklärt wird (SSM). Bestimmen Sie anschließend das Bestimmtheitsmaß R^2 und interpretieren Sie dieses.
- (e) Überprüfen Sie Ihre Berechnungen, indem Sie die Schätzung des Regressionsmodells nun in **R** mit der Funktion **lm** durchführen.